

پیش گزارش آزمایش پنجم (پاده سازی شبکه عصبی RBF)

امیرحسین احمدي آشتیانی ۹۹۲۳۵۰۱

محمدرضا امیری ۹۹۲۶۰۴۰

محمد مهدی نوروزی ۹۹۲۳۰۸۵

(1

Feature	MLP	RBF Network
Layers	Multiple layers (input, hidden, output)	Input, hidden (RBF units), output
Activation Function	Non-linear (sigmoid, ReLU, etc.)	Radial basis functions (Gaussian, etc.)
Training Method	Backpropagation (gradient descent)	Unsupervised (centers) + supervised (weights)
Data Processing	Global representations	Localized, distance-based representations
Use Cases	Wide range (image, NLP, etc.)	Function approximation, localized classification
Scalability	Effective for complex, high-dimensional problems	Struggles with high-dimensional data
Computational Cost	High for deep networks	Lighter, but may need many neurons for complex tasks
Generalization	Global, hierarchical feature learning	Localized patterns, prone to overfitting

شبکه‌های RBF چندلایه:

- شبکه‌های RBF سنتی شامل سه لایه هستند: ورودی، پنهان (با توابع پایه شعاعی) و خروجی.
- در شبکه‌های RBF چندلایه، لایه‌های پنهان متعدد از واحدهای RBF استفاده می‌کنند، اما این معماری به ندرت استفاده می‌شود.

دلایل اصلی عدم توسعه:

- پیچیدگی آموزش: با روش‌های سنتی دشوار است و بازپخش خطا (Backpropagation) در شبکه‌های RBF ناپایدار است.
- بیش‌برازش: RBFها به دلیل ماهیت موضعی (localized) فعال‌سازی، در معماری‌های عمیق به خوبی تعمیم نمی‌دهند.
- مشکلات مقیاس‌پذیری: شبکه‌های RBF در ورودی‌های با ابعاد بالا مشکل دارند و نیاز به تعداد زیادی نرون برای پوشش فضای ورودی دارند که آنها را ناکارآمد از نظر محاسباتی می‌کند.
- غلبه سایر معماری‌ها: شبکه‌های MLP، CNN و ترانسفورمرها عملکرد بهتری در بیشتر وظایف یادگیری عمیق نشان داده‌اند و این باعث کاهش علاقه به شبکه‌های RBF شده است.

عمق شبکه‌های RBF خالص:

- محدودیت نظری برای عمق وجود ندارد، اما در عمل، معماری‌های کم‌عمق ۱-۲ لایه عملکرد بهتری دارند.
- اضافه کردن لایه‌های بیشتر منجر به بازده نزولی می‌شود به دلیل ماهیت موضعی واحدهای RBF.
- شبکه‌های RBF عمیق‌تر، زمینه کلی را از دست می‌دهند و مستعد بیش‌برازش می‌شوند.

نتیجه‌گیری از تحقیقات یادگیری عمیق:

- شبکه‌های RBF چندلایه دشوار برای آموزش، مستعد بیش‌برازش و ناکارآمد از نظر محاسباتی هستند.
- معماری‌های مدرن یادگیری عمیق مانند CNN ها و MLP ها در یادگیری نمایش‌های پیچیده و جهانی مؤثرتر هستند، که منجر به کاهش پژوهش و توسعه شبکه‌های RBF عمیق شده است.

(3)

Method	Pros	Cons	Best Use Case
Grid Search	Simple, exhaustive	Very slow for large spaces	Small datasets or few hyperparameters
Random Search	More efficient than grid	Might miss optimal combinations	Large hyperparameter spaces
Bayesian Optimization	Efficient, balances exploration/exploitation	Complex, expensive	Expensive model training
Genetic Algorithms (GA)	Good for large spaces, escapes local minima	Requires many evaluations	High-dimensional or complex problems
Hyperband	Efficient, early stopping	May prune good configurations early	Large datasets, quick experimentation
Particle Swarm Optimization	Global exploration, easy to parallelize	May converge prematurely	Large search spaces
Simulated Annealing	Avoids local minima, flexible	Sensitive to cooling schedule	Non-convex problems
Neural Architecture Search	Automated, highly performant architectures	Extremely expensive, complex	Research, high-resource environments